

Integração de Monte Carlo

INF2604 – Fundamentos de Computação Gráfica

Waldemar Celes
celes@inf.puc-rio.br

Departamento de Informática, PUC-Rio



Tópicos

Geração de Números Aleatórios

Integração Numérica

Monte Carlo em renderização



Geração de Números Aleatórios



Conceitos de probabilidade

Domínio discreto

- ▶ Exemplo: lançamento de um dado

$$X_i \in \{1, 2, 3, 4, 5, 6\}$$

- ▶ Probabilidade de sair um determinado número

$$p_i = \frac{1}{6}, \quad \sum_i p_i = 1$$



Conceitos de probabilidade

Domínio discreto


- Exemplo: lançamento de um dado

$$X_i \in \{1, 2, 3, 4, 5, 6\}$$

- Probabilidade de sair um determinado número

$$p_i = \frac{1}{6}, \quad \sum_i p_i = 1$$

- Distribuição de probabilidade



Conceitos de probabilidade

Domínio discreto


- Exemplo: lançamento de um dado

$$X_i \in \{1, 2, 3, 4, 5, 6\}$$

- Probabilidade de sair um determinado número

$$p_i = \frac{1}{6}, \quad \sum_i p_i = 1$$

- Distribuição de probabilidade



- Escolhendo X_i a partir de uma variável randômica contínua $\xi \in [0, 1)$

Conceitos de probabilidade

Domínio discreto


- Exemplo: lançamento de um dado

$$X_i \in \{1, 2, 3, 4, 5, 6\}$$

- Probabilidade de sair um determinado número

$$p_i = \frac{1}{6}, \quad \sum_i p_i = 1$$

- Distribuição de probabilidade



- Escolhendo X_i a partir de uma variável randômica contínua $\xi \in [0, 1)$


$$X_i = 1 + \lfloor 6\xi \rfloor$$



Conceitos de probabilidade

Domínio discreto

- ▶ Dado “viciado”: número 5 com 10% a mais de probabilidade de sair



- ▶ Como gerar X_i a partir de ξ ?



Conceitos de probabilidade

Dado “viciado”

$$p = \left\{ \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1.1}{6}, \frac{1}{6} \right\}$$



Conceitos de probabilidade

Dado “viciado”

$$p = \left\{ \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1.1}{6}, \frac{1}{6} \right\}$$

► Normalizando

$$p = \left\{ \frac{1}{6.1}, \frac{1}{6.1}, \frac{1}{6.1}, \frac{1}{6.1}, \frac{1.1}{6.1}, \frac{1}{6.1} \right\}, \quad \sum_i p_i = 1$$




Conceitos de probabilidade

Dado “viciado”

- Função de distribuição acumulada (*cumulative distribution function* (CDF))


$$P(x) = P_r\{X \leq x\}$$



Conceitos de probabilidade

Dado “viciado”

- Geração de X_i a partir de ξ ?



$$\sum_{j=1}^{i-1} p_j \leq \xi < \sum_{j=1}^i p_j$$



Geração de números aleatórios seguindo p_i

Distribuição de probabilidade discreta: **Método da inversão**

- ▶ Determinar X_i com base em ξ
 - ▶ Dado a distribuição discreta p_i normalizada

$$\sum_{i=0}^{n-1} p_i = 1$$

- ▶ Calcula CDF

$$P(i) = \sum_{j=0}^i p_j$$

- ▶ Usa gerador padrão

$$\xi \in [0, 1)$$

- ▶ Calcula amostra como valor inverso

$$X_i / P(i-1) \leq \xi < P(i)$$



Domínio contínuo

Probability Density Function (PDF)

- ▶ Função de densidade de probabilidade : $p(x)$
 - ▶ Necessariamente não negativo

$$p(x) = \frac{dP(x)}{dx}$$

- ▶ Integral no domínio necessariamente igual a 1

$$\int_D p(x)dx = 1$$

- ▶ Avaliação da probabilidade de um valor estar num intervalo

$$P(x \in [a, b]) = \int_a^b p(x)dx$$



Geração de números aleatórios seguindo $p(x)$

Distribuição de probabilidade qualquer contínua: **Método da inversão**

- ▶ Determinar X_i de um PDF arbitrário $p(x)$

- ▶ Normalizado

$$\int_D p(x)dx = 1$$

- ▶ Calcula CDF

$$P(x) = \int_0^x p(x')dx'$$

- ▶ Calcula a inversa

$$P^{-1}(x)$$

- ▶ Usa gerador padrão

$$\xi \in [0, 1)$$


- ▶ Calcula amostra como valor inverso

$$X_i = P^{-1}(\xi)$$



Geração no caso contínuo

Exemplo com distribuição exponencial: $p(x) \propto e^{-ax}$



Geração no caso contínuo

Exemplo com distribuição exponencial: $p(x) \propto e^{-ax} \quad \therefore \quad p(x) = c e^{-ax}$



Geração no caso contínuo

Exemplo com distribuição exponencial: $p(x) \propto e^{-ax} \quad \therefore \quad p(x) = c e^{-ax}$

- Normalizando a distribuição (considerando o intervalo $[0, \infty]$):

$$\int_0^{\infty} c e^{-ax} dx = -\frac{c}{a} e^{-ax} \Big|_0^{\infty} = \frac{c}{a} = 1$$



Geração no caso contínuo

Exemplo com distribuição exponencial: $p(x) \propto e^{-ax} \quad \therefore \quad p(x) = c e^{-ax}$

- Normalizando a distribuição (considerando o intervalo $[0, \infty]$):

$$\int_0^{\infty} c e^{-ax} dx = -\frac{c}{a} e^{-ax} \Big|_0^{\infty} = \frac{c}{a} = 1$$

- Então $c = a$ e nosso PDF deve ser $p(x) = a e^{-ax}$. Achando $P(x)$:

$$P(x) = \int_0^x a e^{-ax'} dx' = 1 - e^{-ax}$$



Geração no caso contínuo

Exemplo com distribuição exponencial: $p(x) \propto e^{-ax} \quad \therefore \quad p(x) = c e^{-ax}$

- Normalizando a distribuição (considerando o intervalo $[0, \infty]$):

$$\int_0^{\infty} c e^{-ax} dx = -\frac{c}{a} e^{-ax} \Big|_0^{\infty} = \frac{c}{a} = 1$$

- Então $c = a$ e nosso PDF deve ser $p(x) = a e^{-ax}$. Achando $P(x)$:

$$P(x) = \int_0^x a e^{-ax'} dx' = 1 - e^{-ax}$$

- Invertendo:

$$P^{-1} = -\frac{\ln(1-x)}{a}$$



Geração no caso contínuo

Exemplo com distribuição exponencial: $p(x) \propto e^{-ax} \quad \therefore \quad p(x) = c e^{-ax}$

- Normalizando a distribuição (considerando o intervalo $[0, \infty]$):

$$\int_0^{\infty} c e^{-ax} dx = -\frac{c}{a} e^{-ax} \Big|_0^{\infty} = \frac{c}{a} = 1$$

- Então $c = a$ e nosso PDF deve ser $p(x) = a e^{-ax}$. Achando $P(x)$:

$$P(x) = \int_0^x a e^{-ax'} dx' = 1 - e^{-ax}$$

- Invertendo:

$$P^{-1} = -\frac{\ln(1-x)}{a}$$

- Amostra:


$$X = -\frac{\ln(1-\xi)}{a}$$



Geração no caso contínuo

Exemplo com distribuição exponencial: $p(x) \propto e^{-ax}$, para $a = 1$

```
for i = 1, 1000 do  
  local xi = -math.log(1-math.random())  
  print(xi)  
end
```



Valor esperado e variância

Valor esperado (valor médio)

- Valor médio de uma função considerando a distribuição $p(x)$ no domínio

$$E_p[f(x)] = \int_D f(x)p(x)dx$$



Valor esperado e variância


Valor esperado (valor médio)

- ▶ Exemplo: valor esperado de $\cos x$ no domínio $[0, \pi]$
 - ▶ Assumindo distribuição constante: $p(x) = k$
 - ▶ Como o PDF $p(x)$ tem que integrar para o valor 1 no domínio

$$\int_0^{\pi} k \, dx = 1 \quad \therefore \quad p(x) = k = \frac{1}{\pi}$$

- ▶ Então:

$$E[\cos x] = \int_0^{\pi} \frac{\cos x}{\pi} dx = \frac{1}{\pi} (\sin \pi - \sin 0) = 0$$



Valor esperado e variância

Variância

- ▶ Mede a dispersão estatística dos valores
 - ▶ O quão longe, em geral, eles se encontram do valor esperado

$$V[f(x)] = E [(f(x) - E[f(x)])^2]$$



Valor esperado e variância

Variância

- ▶ Mede a dispersão estatística dos valores
 - ▶ O quão longe, em geral, eles se encontram do valor esperado

$$V[f(x)] = E[(f(x) - E[f(x)])^2]$$

- ▶ Observe:

$$\mu = E[f(x)]$$

$$\sigma^2 = E[(f(x) - \mu)^2]$$

$$\sigma^2 = E[f(x)^2 - 2\mu f(x) + \mu^2] = E[f(x)^2] - 2\mu E[f(x)] + \mu^2$$

$$\sigma^2 = E[f(x)^2] - 2\mu^2 + \mu^2 = E[f(x)^2] - \mu^2$$

- ▶ Logo:

$$V[f(x)] = E[f(x)^2] - E[f(x)]^2$$



Valor esperado e variância

- ▶ Exemplo: variância de $\cos x$ no domínio $[0, \pi]$

$$\begin{aligned} V[f(x)] &= E[\cos^2 x] - E[\cos x]^2 \\ &= \int_0^\pi \frac{\cos^2 x}{\pi} dx - 0 \\ &= \frac{1}{2} \end{aligned}$$




Integração Numérica



Integração numérica

Exemplo: integração da função $f(x) = 2.4 - (x - \frac{\pi}{2})^2$




Integração numérica

Integração da função $f(x) = 2.4 - (x - \frac{\pi}{2})^2$

► Método do ponto médio

$$\int_a^b f(x)dx = h \sum_{i=0}^{n-1} f\left(\frac{x_i + x_{i+1}}{2}\right)$$

$$\text{onde: } h = \frac{b-a}{n}$$



Integração numérica

Integração da função $f(x) = 2.4 - (x - \frac{\pi}{2})^2$

► Método do ponto médio



$$\int_a^b f(x)dx = h \sum_{i=0}^{n-1} f\left(\frac{x_i + x_{i+1}}{2}\right)$$

$$\text{onde: } h = \frac{b-a}{n}$$

► Método de Monte Carlo

$$\int_a^b f(x)dx = \frac{1}{n} (b-a) \sum_{i=0}^{n-1} f(x_i)$$

$$\text{onde: } x_i = a + \xi(b-a)$$



Integração numérica

Exemplo

$$\int_0^{\pi} 2.4 - \left(x - \frac{\pi}{2}\right)^2 dx$$

- ▶ Solução analítica: 4.956
- ▶ Ponto médio com 10 intervalos: 4.982 ($e=0.026$)



Integração numérica

Exemplo

$$\int_0^{\pi} 2.4 - \left(x - \frac{\pi}{2}\right)^2 dx$$

- ▶ Solução analítica: 4.956
- ▶ Ponto médio com 10 intervalos: 4.982 ($e=0.026$)
- ▶ Monte Carlo com 10 amostras
 - ▶ 4.841 ($e=0.115$)



Integração numérica

Exemplo

$$\int_0^{\pi} 2.4 - \left(x - \frac{\pi}{2}\right)^2 dx$$

- ▶ Solução analítica: 4.956
- ▶ Ponto médio com 10 intervalos: 4.982 ($e=0.026$)
- ▶ Monte Carlo com 10 amostras
 - ▶ 4.841 ($e=0.115$)
 - ▶ 5.037 ($e=0.081$)
 - ▶ 4.513 ($e=0.443$)



Integração numérica

Exemplo

$$\int_0^{\pi} 2.4 - \left(x - \frac{\pi}{2}\right)^2 dx$$

- ▶ Solução analítica: 4.956
- ▶ Ponto médio com 10 intervalos: 4.982 ($e=0.026$)
- ▶ Monte Carlo com 10 amostras
 - ▶ 4.841 ($e=0.115$)
 - ▶ 5.037 ($e=0.081$)
 - ▶ 4.513 ($e=0.443$)
- ▶ Converge?



Integração numérica

Exemplo

$$\int_0^{\pi} 2.4 - \left(x - \frac{\pi}{2}\right)^2 dx$$

- ▶ Solução analítica: 4.956
- ▶ Ponto médio com 10 intervalos: 4.982 ($e=0.026$)
- ▶ Monte Carlo com 10 amostras
 - ▶ 4.841 ($e=0.115$)
 - ▶ 5.037 ($e=0.081$)
 - ▶ 4.513 ($e=0.443$)
- ▶ Converge?
 - ▶ Monte Carlo com 1000 amostras
 - ▶ 4.951 ($e=0.005$)
 - ▶ 4.906 ($e=0.050$)
 - ▶ 4.981 ($e=0.025$)



Integração numérica

Exemplo

$$\int_0^{\pi} 2.4 - \left(x - \frac{\pi}{2}\right)^2 dx$$

- ▶ Solução analítica: 4.956
- ▶ Ponto médio com 10 intervalos: 4.982 ($e=0.026$)
- ▶ Monte Carlo com 10 amostras
 - ▶ 4.841 ($e=0.115$)
 - ▶ 5.037 ($e=0.081$)
 - ▶ 4.513 ($e=0.443$)
- ▶ Converge?
 - ▶ Monte Carlo com 1000 amostras
 - ▶ 4.951 ($e=0.005$)
 - ▶ 4.906 ($e=0.050$)
 - ▶ 4.981 ($e=0.025$)
- ▶ É efetivo?



Integração numérica

Exemplo

$$\int_0^{\pi} 2.4 - \left(x - \frac{\pi}{2}\right)^2 dx$$

- ▶ Desempenho com baixa amostragem
 - ▶ Solução analítica: 4.956
 - ▶ Ponto médio com 2 intervalos: 5.602 ($e=0.646$)
 - ▶ Monte Carlo com 2 amostras
 - ▶ 6.630 ($e=1.674$)
 - ▶ 5.432 ($e=0.476$)
 - ▶ 4.942 ($e=0.014$)
 - ▶ 5.850 ($e=0.894$)



Integração numérica

Exemplo

$$\int_0^{\pi} 2.4 - \left(x - \frac{\pi}{2}\right)^2 dx$$

- ▶ Desempenho com baixa amostragem
 - ▶ Solução analítica: 4.956
 - ▶ Ponto médio com 2 intervalos: 5.602 ($e=0.646$)
 - ▶ Monte Carlo com 2 amostras
 - ▶ 6.630 ($e=1.674$)
 - ▶ 5.432 ($e=0.476$)
 - ▶ 4.942 ($e=0.014$)
 - ▶ 5.850 ($e=0.894$)

Observação

- ▶ Determinadas amostragem resultam em resultados muito bons



Integração numérica

Exemplo

$$\int_0^{\pi} 2.4 - \left(x - \frac{\pi}{2}\right)^2 dx$$

- ▶ Desempenho com baixa amostragem
 - ▶ Solução analítica: 4.956
 - ▶ Ponto médio com 2 intervalos: 5.602 ($e=0.646$)
 - ▶ Monte Carlo com 2 amostras
 - ▶ 6.630 ($e=1.674$)
 - ▶ 5.432 ($e=0.476$)
 - ▶ 4.942 ($e=0.014$)
 - ▶ 5.850 ($e=0.894$)

Observação

- ▶ Determinadas amostragem resultam em resultados muito bons
- ▶ Como fazer uma amostragem adequada?



Monte Carlo

Estimador de Monte Carlo

- Função 1D com distribuição de amostras uniforme

$$\int_a^b f(x)dx \approx F_N = \frac{b-a}{N} \sum_{i=1}^N f(X_i)$$

- onde $X_i \in [a, b]$ é um número aleatório com $p(x) = \frac{1}{b-a}$



Estimador de Monte Carlo

Converge?

► De fato: $E[F_N] = \int_a^b f(x)dx$

$$\begin{aligned} E[F_N] &= E \left[\frac{b-a}{N} \sum_{i=1}^N f(X_i) \right] \\ &= \frac{b-a}{N} \sum_{i=1}^N E[f(X_i)] \\ &= \frac{b-a}{N} \sum_{i=1}^N \int_a^b f(x) p(x) dx \end{aligned}$$

► como $p(x) = \frac{1}{b-a}$, tem-se:

$$E[F_N] = \frac{1}{N} \sum_{i=1}^N \int_a^b f(x) = \int_a^b f(x) dx$$



Estimador de Monte Carlo

Generalizando para amostragens que seguem uma distribuição de $p(x)$:

$$F_N = \frac{1}{N} \sum_{i=1}^N \frac{f(X_i)}{p(X_i)}$$



Estimador de Monte Carlo

Generalizando para amostragens que seguem uma distribuição de $p(x)$:

$$F_N = \frac{1}{N} \sum_{i=1}^N \frac{f(X_i)}{p(X_i)}$$

- Intuitivamente: amostras menos prováveis, quando utilizadas, têm peso maior para compensar baixa ocorrência



Estimador de Monte Carlo

Generalizando para amostragens que seguem uma distribuição de $p(x)$:

$$F_N = \frac{1}{N} \sum_{i=1}^N \frac{f(X_i)}{p(X_i)}$$

- ▶ Intuitivamente: amostras menos prováveis, quando utilizadas, têm peso maior para compensar baixa ocorrência
- ▶ De novo, demonstra-se que:

$$E[F_N] = \int_a^b f(x) dx$$



Estimador de Monte Carlo

Retomando

$$F_N = \frac{1}{N} \sum_{i=1}^N \frac{f(X_i)}{p(X_i)}$$

- Qual PDF usar?



Estimador de Monte Carlo

Retomando

$$F_N = \frac{1}{N} \sum_{i=1}^N \frac{f(X_i)}{p(X_i)}$$

► Qual PDF usar?

► Se usarmos $p(x) = k f(x)$:

$$E[F_N] = E \left[\frac{1}{N} \sum_{i=1}^N \frac{f(X_i)}{p(X_i)} \right]$$

$$E[F_N] = \frac{1}{N} \sum_{i=1}^N E \left[\frac{1}{k} \right] = \frac{1}{k}$$

► Como o valor independe de X_i , uma amostra qualquer resulta no valor correto



Estimador de Monte Carlo

Retomando

$$F_N = \frac{1}{N} \sum_{i=1}^N \frac{f(X_i)}{p(X_i)}$$

► Qual PDF usar?

► Se usarmos $p(x) = k f(x)$:

$$E[F_N] = E \left[\frac{1}{N} \sum_{i=1}^N \frac{f(X_i)}{p(X_i)} \right]$$

$$E[F_N] = \frac{1}{N} \sum_{i=1}^N E \left[\frac{1}{k} \right] = \frac{1}{k}$$

► Como o valor independe de X_i , uma amostra qualquer resulta no valor correto

► Mas:

$$k = \frac{1}{\int_D f(x) dx}$$



Estimador de Monte Carlo

Qual PDF usar?


- Uma função conhecida que se aproxima de $f(x)$



Estimador de Monte Carlo

Qual PDF usar?

- Uma função conhecida que se aproxima de $f(x)$
 - No nosso exemplo: $f(x) = 2.4 - (x - \frac{\pi}{2})^2$
 - Uso de $p(x) = k \sin(x)$



Estimador de Monte Carlo

Exemplo: $f(x) = 2.4 - (x - \frac{\pi}{2})^2$

► Usando $p(x) = k \sin x$

► Normaliza

$$\int_0^{\pi} k \sin(x) dx = k[-\cos x]_0^{\pi} = k[-(-2)] = 2k = 1 \quad \therefore k = 1/2$$

► Calcula CDF

$$P(x) = \int_0^x \frac{\sin x'}{2} dx' = -\frac{1}{2} \cos x \Big|_0^x = -\frac{1}{2}(\cos x - 1) = \frac{1}{2}(1 - \cos x)$$

► Calcula inversa

$$y = \frac{1}{2}(1 - \cos x) \quad \therefore x = \cos^{-1}(1 - 2y)$$

► Calcula amostra

$$X = \cos^{-1}(1 - 2\xi)$$



Estimador de Monte Carlo

Exemplo: $f(x) = 2.4 - (x - \frac{\pi}{2})^2$

- ▶ Solução analítica: 4.956
- ▶ Solução ponto médio (2 amostras)
 - ▶ 5.602 (e=0.646)
- ▶ Solução Monte Carlo (2 amostras): $p(x) = k$
 - ▶ 7.302 (e=2.346)
 - ▶ 5.850 (e=0.894)
 - ▶ 4.942 (e=0.014)
 - ▶ 6.744 (e=1.788)



Estimador de Monte Carlo

Exemplo: $f(x) = 2.4 - (x - \frac{\pi}{2})^2$

- ▶ Solução analítica: 4.956
- ▶ Solução ponto médio (2 amostras)
 - ▶ 5.602 (e=0.646)
- ▶ Solução Monte Carlo (2 amostras): $p(x) = k$
 - ▶ 7.302 (e=2.346)
 - ▶ 5.850 (e=0.894)
 - ▶ 4.942 (e=0.014)
 - ▶ 6.744 (e=1.788)
- ▶ Solução Monte Carlo (2 amostras): $p(x) = \frac{\sin x}{2}$
 - ▶ 5.261 (e=0.305)
 - ▶ 5.130 (e=0.174)
 - ▶ 5.010 (e=0.054)
 - ▶ 4.826 (e=0.130)



Monte Carlo em renderização



Geração multidimensional

Gerar (X, Y) com base no pdf $p(x, y)$

- Distribuição separável

$$p(x, y) = p_x(x)p_y(y)$$

- Basta gerar X e Y independentemente de acordo com p_x e p_y



Geração multidimensional

Gerar (X, Y) com base no pdf $p(x, y)$

- ▶ Distribuição não separável
 - ▶ Calcula uma função densidade marginal
 - ▶ Densidade média de um x para todos os possíveis y

$$p(x) = \int p(x, y) dy$$

- ▶ Calcula a função densidade condicional
 - ▶ Função densidade de y para um dado x

$$p(y|x) = \frac{p(x, y)}{p(x)}$$

- ▶ Procedimento
 - ▶ Usa $p(x)$ para gerar X
 - ▶ Usa $p(y|x)$ para gerar Y , dado o x já escolhido



Transformação entre distribuições

- ▶ Suponha uma amostra aleatória X que segue a distribuição $p_x(x)$
- ▶ Suponha a transformação bijetora $Y = T(X)$

Tem-se:

$$p_y(y) = p_y(T(x)) = \frac{p_x(x)}{|J_T(x)|}$$

- ▶ onde J_T é a matrix Jacobiana:

$$\begin{bmatrix} \partial T_1 / \partial x_i & \cdots & \partial T_1 / \partial x_n \\ \vdots & \ddots & \vdots \\ \partial T_n / \partial x_i & \cdot & \partial T_n / \partial x_n \end{bmatrix}$$



Transformação entre distribuições

Exemplo: Coordenadas polares

$$x = r \cos \theta$$

$$y = r \sin \theta$$

- ▶ Dado $p(r, \theta)$, queremos determinar $p(x, y)$

- ▶ Matrix Jacobiana

$$J_T = \begin{bmatrix} \partial x / \partial r & \partial x / \partial \theta \\ \partial y / \partial r & \partial y / \partial \theta \end{bmatrix} = \begin{bmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{bmatrix}$$

- ▶ Determinante

$$|J_T| = r \cos^2 \theta + r \sin^2 \theta = r$$

- ▶ Logo

$$p(x, y) = \frac{p(r, \theta)}{r} \quad \therefore \quad p(r, \theta) = r p(x, y)$$



Amostragem uniforme em um hemisfério unitário

Amostragem de ω no hemisfério Ω considerando $p(w) = c$

- Normalizando $p(x)$

$$\int_{\Omega} p(w) dw = 1 \Rightarrow c \int_{\Omega} dw = 1 \Rightarrow c = \frac{1}{2\pi}$$

- Transformação para coordenadas esféricas: $p(\theta, \phi)$

$$dw = \sin \theta d\theta d\phi \quad \therefore \quad p(\theta, \phi) = \frac{\sin \theta}{2\pi}$$

- Densidade marginal $p(\theta)$

$$p(\theta) = \int_0^{2\pi} p(\theta, \phi) d\phi = \int_0^{2\pi} \frac{\sin \theta}{2\pi} d\phi = \sin \theta$$

- Densidade condicional $p(\phi|\theta)$

$$p(\phi|\theta) = \frac{p(\theta, \phi)}{p(\theta)} = \frac{\sin \theta}{2\pi \sin \theta} = \frac{1}{2\pi}$$



Amostragem uniforme em um hemisfério unitário

Usando o método de inversão para cada dimensão

- Calcula CDFs

$$P(\theta) = \int_0^\theta \sin\theta' d\theta' = 1 - \cos\theta$$

$$P(\phi|\theta) = \int_0^\phi \frac{1}{2\pi} d\phi' = \frac{\phi}{2\pi}$$

- Calcula inversas (substituindo $1 - \xi$ por ξ)

$$\theta = \cos^{-1}\xi_1$$

$$\phi = 2\pi\xi_2$$



$$\int \sin x = -\cos x$$



Amostragem uniforme em um hemisfério unitário

► Obtendo (x, y, z)

$$x = \sin\theta \cos\phi = \sqrt{1 - \xi_1^2} \cos(2\pi\xi_2)$$

$$y = \sin\theta \sin\phi = \sqrt{1 - \xi_1^2} \sin(2\pi\xi_2)$$

$$z = \cos\theta = \xi_1$$



$$\sin(\cos^{-1}(x)) = \sqrt{1 - x^2}$$



Amostragem uniforme em uma esfera unitária

De forma equivalente, chega-se a:

$$x = \sqrt{1 - z^2} \cos(2\pi\xi_2)$$

$$y = \sqrt{1 - z^2} \sin(2\pi\xi_2)$$

$$z = 1 - 2\xi_1$$



Amonstragem uniforme em um disco unitário

Amostragem ruim

$$r = \xi_1$$

$$\theta = 2\pi\xi_2$$




Amonstragem uniforme em um disco unitário

Amostragem ruim

$$r = \xi_1$$

$$\theta = 2\pi\xi_2$$

Resultado alcançado




Amonstragem uniforme em um disco unitário

Amostragem ruim


$$r = \xi_1$$

$$\theta = 2\pi\xi_2$$

Resultado alcançado



Resultado desejado



Amonstragem uniforme em um disco unitário

Amostragem uniforme correta

- ▶ PDF de amostragem uniforme

$$p(x, y) = k \quad \therefore \quad p(x, y) = \frac{1}{\pi}$$

- ▶ Em coordenadas polares

$$p(r, \theta) = r p(x, y) = \frac{r}{\pi}$$

- ▶ PDFs separadas

$$p(r) = \int_0^{2\pi} p(r, \theta) d\theta = \int_0^{2\pi} \frac{r}{\pi} d\theta = 2r$$
$$p(\theta|r) = \frac{p(r, \theta)}{p(r)} = \frac{1}{2\pi}$$



Amonstragem uniforme em um disco unitário

Amostragem uniforme correta

► CDFs

$$P(r) = \int_0^{r'} p(r) dr = \int_0^{r'} 2r dr = r^2$$

$$P(\theta) = \int_0^{2\pi} p(\theta|r) d\theta = \int_0^{\theta} \frac{1}{2\pi} d\theta' = \frac{\theta}{2\pi}$$

► Inversas

$$r = \sqrt{\xi_1}$$

$$\theta = 2\pi\xi_2$$



Amonstragem do hemisfério ponderada pelo cosseno

PDF: $p(w) \propto \cos\theta$

► Normalizando

$$\int_{\Omega} p(w) dw = 1$$

$$\int_{\Omega} c \cos\theta dw = 1$$

$$\int_0^{2\pi} \int_0^{\frac{\pi}{2}} c \cos\theta \sin\theta d\theta d\phi = 1$$

$$c2\pi \int_0^{\frac{\pi}{2}} \cos\theta \sin\theta d\theta = 1$$

$$c2\pi \frac{\sin^2\theta}{2} \Big|_0^{\frac{\pi}{2}} = 1$$

$$c2\pi \frac{1}{2} = 1 \quad \therefore \quad c = \frac{1}{\pi}$$



Amonstragem do hemisfério ponderada pelo cosseno

Logo:

$$p(\theta, \phi) = \frac{1}{\pi} \cos\theta \sin\theta$$

Seguindo os passos:

- Densidade marginal $p(\theta)$

$$p(\theta) = \int_0^{2\pi} p(\theta, \phi) d\phi = \int_0^{2\pi} \frac{1}{\pi} \cos\theta \sin\theta d\phi = 2 \cos\theta \sin\theta$$

- Densidade condicional $p(\phi|\theta)$

$$p(\phi|\theta) = (p(\theta, \phi)/p(\theta)) = \frac{1}{\pi} \frac{\cos\theta \sin\theta}{2 \cos\theta \sin\theta} = \frac{1}{2\pi}$$



Amonstragem do hemisfério ponderada pelo cosseno

Usando o método de inversão para cada dimensão

- Calcula CDFs

$$P(\theta) = \int_0^\theta 2 \cos\theta' \sin\theta' d\theta' = \sin^2\theta$$

$$P(\phi|\theta) = \int_0^\phi \frac{1}{2\pi} d\phi' = \frac{\phi}{2\pi}$$

- Calcula inversas

$$\xi_1 = \sin^2\theta \quad \therefore \quad \theta = \sin^{-1}\sqrt{\xi_1}$$


$$\xi_2 = \frac{\phi}{2\pi} \quad \therefore \quad \phi = 2\pi\xi_2$$



Amonstragem do hemisfério ponderada pelo cosseno

Método de Malleys

- ▶ Amostragem uniforme no disco projetada no hemisfério



- ▶ Amostragem uniforme no disco (r, ϕ)

$$r = \sqrt{\xi_1}$$

$$\phi = 2\pi\xi_2$$

- ▶ Na projeção para o hemisfério unitário

$$\sin\theta = r$$

- ▶ Logo, amostras projetadas no hemisfério

$$\theta = \sin^{-1}\sqrt{\xi_1}$$

$$\phi = 2\pi\xi_2$$

