

Renderizador Metropolis

INF2604 – Fundamentos de Computação Gráfica

Waldemar Celes
celes@inf.puc-rio.br

Departamento de Informática, PUC-Rio



Tópicos

Amostragem Metropolis

Integrador Metropolis



Amostragem Metropolis



Amostragem Metropolis

Criar função PDF $p(x) \propto f(x)$

- ▶ Método da inversão

- ▶ Exige calcular integral: $p(x) = \frac{f(x)}{\int_{\Omega} f(x) d\Omega}$



Amostragem Metropolis

Criar função PDF $p(x) \propto f(x)$

- ▶ Método da inversão

- ▶ Exige calcular integral: $p(x) = \frac{f(x)}{\int_{\Omega} f(x) d\Omega}$

- ▶ Amostragem Metropolis

- ▶ Baseia-se apenas em avaliação de $f(X_i)$

- ▶ Requer um determinado número de amostras para alcançar equilíbrio



Amostragem Metropolis

Amostragem por mutação

- ▶ Dado X , obtém X' , e assim sucessivamente
- ▶ Usa um processo de mutação, com probabilidade de transição: $T(X \rightarrow X')$
- ▶ Avalia probabilidade de aceitação da nova amostra: $a(X \rightarrow X')$



Amostragem Metropolis

Amostragem por mutação

- ▶ Dado X , obtém X' , e assim sucessivamente
- ▶ Usa um processo de mutação, com probabilidade de transição: $T(X \rightarrow X')$
- ▶ Avalia probabilidade de aceitação da nova amostra: $a(X \rightarrow X')$



Amostragem Metropolis: Propriedade

Balanceamento após equilíbrio da distribuição

- ▶ Deseja-se $p(x) \propto f(x)$ após equilíbrio
- ▶ Probabilidade de ir de $X \rightarrow X'$ deve ser igual a de $X' \rightarrow X$

$$P(X) = T(X \rightarrow X')a(X \rightarrow X') = T(X' \rightarrow X)a(X' \rightarrow X) = P(X')$$

- ▶ Para $p(x)$ ser estacionária, impõe-se:

$$\begin{aligned} p(X)T(X \rightarrow X')a(X \rightarrow X') &= p(X')T(X' \rightarrow X)a(X' \rightarrow X) \\ cf(X)T(X \rightarrow X')a(X \rightarrow X') &= cf(X')T(X' \rightarrow X)a(X' \rightarrow X) \\ f(X)T(X \rightarrow X')a(X \rightarrow X') &= f(X')T(X' \rightarrow X)a(X' \rightarrow X) \end{aligned}$$



Amostragem Metropolis

Probabilidade de aceitação

- ▶ Para maximizar a taxa de alcance de equilíbrio

$$a(X \rightarrow X') = \min \left(1, \frac{f(X')T(X' \rightarrow X)}{f(X)T(X \rightarrow X')} \right)$$

- ▶ Assumindo que a probabilidade de transição é simétrica

$$a(X \rightarrow X') = \min \left(1, \frac{f(X')}{f(X)} \right)$$

- ▶ Isto assegura que uma nova amostra $X'/f(X') > f(X)$ tem 100% de aceitação
- ▶ Se nova amostra não for aceita, re-usa amostra anterior



Amostragem Metropolis

Algoritmo básico

```
 $X = X_0$   
for  $i = 1$  to  $n$   
     $X' = mutate(X)$   
     $a = accept(X, X')$   
    if  $\xi < a$   
         $X = X'$   
     $record(X)$ 
```



Amostragem Metropolis

Algoritmo básico

```
 $X = X_0$   
for  $i = 1$  to  $n$   
     $X' = mutate(X)$   
     $a = accept(X, X')$   
    if  $\xi < a$   
         $X = X'$   
     $record(X)$ 
```

- Difícil amostrar regiões onde $f(x)$ é pequeno



Amostragem Metropolis

Algoritmo por expectativa de valor

- ▶ Utiliza pesos associados às amostras
- ▶ Suaviza mais rapidamente a distribuição

```
 $X = X_0$   
for  $i = 1$  to  $n$   
     $X' = mutate(X)$   
     $a = accept(X, X')$   
     $record(X, 1 - a)$   
     $record(X', a)$   
    if  $\xi < a$   
         $X = X'$ 
```



Estratégias de mutação

Escolha livre para a **estratégia de mutação**

- ▶ Requer avaliação da probabilidade de transição $T(X \rightarrow X')$, se não for simétrica
- ▶ Princípios
 1. Mutação deve propor grandes mudanças
 - ▶ A fim de permitir a cobertura do domínio de forma mais rápida
 2. Mutação deve gerar amostras próximas
 - ▶ Evitar muitas amostras rejeitadas ($f(X) \gg f(X')$) em sequência
 - ▶ Evitar o re-uso de amostras várias vezes (aumento de variância)



Estratégias de mutação

Exemplos de mutações (ambas simétricas)

- ▶ Exploração da vizinhança

$$X' = (X \pm s\xi) \in [0, 1]$$

- ▶ Aleatória


$$X' = \xi$$



Exemplo

Considere a função

$$f(x) = \begin{cases} (x - 0.5)^2 & 0 \leq x \leq 1 \\ 0 & \text{caso contrário} \end{cases}$$



Exemplo

Estratégias de mutação

- Fórmulas de mutações

$$M_1 : X' = \xi \qquad M_2 : X' = X + 0.1(\xi - 0.5)$$



Exemplo

Estratégias de mutação


► Fórmulas de mutações

$$M_1 : X' = \xi$$


$$M_2 : X' = X + 0.1(\xi - 0.5)$$

Histogramas

► Usando apenas M_1




► Usando $M_1(10\%)$ e $M_2(90\%)$




Exemplo

Histogramas usando apenas M_2

► 10.000 iterações



► 300.000 iterações



Amostragem Metropolis

Viés do início da geração

- ▶ Como escolher X_0 ?
 - ▶ O processo de mutação assume que X_i foi gerado de forma proporcional a $f(x)$
 - ▶ Como X_0 não é proporcional a $f(x)$ tem-se um viés no início do processo



Amostragem Metropolis

Viés do início da geração

- ▶ Como escolher X_0 ?
 - ▶ O processo de mutação assume que X_i foi gerado de forma proporcional a $f(x)$
 - ▶ Como X_0 não é proporcional a $f(x)$ tem-se um viés no início do processo
- ▶ Solução 1: descartar n primeiras amostras



Amostragem Metropolis

Viés do início da geração

- ▶ Como escolher X_0 ?
 - ▶ O processo de mutação assume que X_i foi gerado de forma proporcional a $f(x)$
 - ▶ Como X_0 não é proporcional a $f(x)$ tem-se um viés no início do processo
- ▶ Solução 1: descartar n primeiras amostras
 - ▶ A obtenção dessas amostras pode ser cara
 - ▶ Difícil determinar o valor de n necessário



Amostragem Metropolis

Viés do início da geração

- ▶ Solução 2: usar outro método de amostragem $X_0 \sim p(x)$
 - ▶ Associa um peso às amostras geradas

$$w = \frac{f(X_0)}{p(X_0)}$$

- ▶ Elimina o viés
 - ▶ $f(X_0)$ não pode ser zero



Amostragem Metropolis

Viés do início da geração

- ▶ Solução 2: usar outro método de amostragem $X_0 \sim p(x)$
 - ▶ Associa um peso às amostras geradas

$$w = \frac{f(X_0)}{p(X_0)}$$

- ▶ Elimina o viés
 - ▶ $f(X_0)$ não pode ser zero
- ▶ Solução robusta
 - ▶ Usa $p(x)$ para gerar N candidatos: $Y_0, Y_1, \dots, Y_{N-1}$
 - ▶ Escolhe X_0 dentre os Y_i usando $p(Y_i)$ como probabilidade
 - ▶ Associa o peso w como sendo o valor médio dos w_i



Integrador Metropolis



Transporte de Luz por Metropolis

Metropolis Light Transport (MLT)

- ▶ Vantajoso para situações de iluminação complexa
- ▶ Caminhos são gerados por mutações de caminhos anteriores
 - ▶ Permite explorar o espaço do caminho localmente
 - ▶ Pode ser desafiador aplicar uma mutação local em um caminho
 - ▶ Por exemplo, se um vértice de uma reflexão especular for localmente modificado, perde-se toda a contribuição especular.



Transporte de Luz por Metropolis

Metropolis Light Transport (MLT)

- ▶ Vantajoso para situações de iluminação complexa
- ▶ Caminhos são gerados por mutações de caminhos anteriores
 - ▶ Permite explorar o espaço do caminho localmente
 - ▶ Pode ser desafiador aplicar uma mutação local em um caminho
 - ▶ Por exemplo, se um vértice de uma reflexão especular for localmente modificado, perde-se toda a contribuição especular.
- ▶ Referência:
 - ▶ "A Simple and Robust Mutation Strategy for the Metropolis Light Transport Algorithm", by Kelemen et al., 2002



Iluminação global

Contribuição no pixel j por Monte Carlo

$$L_j = \int_{\mathcal{P}} f(\mathbf{z}) d\mathbf{z} \approx \frac{1}{M} \sum_{i=1}^M \frac{f(\mathbf{z}_i)}{p(\mathbf{z}_i)}$$

- ▶ $\mathbf{z}_i$: representa um caminho de transporte de luz
- ▶ $p(\mathbf{z}_i)$: probabilidade de se escolher o caminho
 - ▶ Idealmente, proporcional a $f(\mathbf{z}_i)$



Iluminação global

Contribuição no pixel j por Monte Carlo

$$L_j = \int_{\mathcal{P}} f(\mathbf{z}) d\mathbf{z} \approx \frac{1}{M} \sum_{i=1}^M \frac{f(\mathbf{z}_i)}{p(\mathbf{z}_i)}$$

- ▶ $\mathbf{z}_i$: representa um caminho de transporte de luz
- ▶ $p(\mathbf{z}_i)$: probabilidade de se escolher o caminho
 - ▶ Idealmente, proporcional a $f(\mathbf{z}_i)$
- ▶ Normalização de $p(\mathbf{z})$
 - ▶ Função de contribuição escalar: $I(\mathbf{z})$
 - ▶ Por exemplo, luminância do r, g, b computado
 - ▶ $l = 0.299r + 0.587g + 0.114b$

$$p(\mathbf{z}) = \frac{I(\mathbf{z})}{b} \text{ com } b = \int_{\mathcal{P}} I(\mathbf{z}) d\mathbf{z}$$



Amostragem de caminhos

Baseado em amostragem por importância local e MIS

- ▶ Amostragem baseada em BRDF
- ▶ Amostragem baseada em fonte de luz
- ▶ Amostragem de interrupção (roleta russa)



Amostragem de caminhos

Espaço de amostragem primário

- ▶ Caminho construído a partir de geração de número randômicos: $u = f(\xi)$
 - ▶ Amostragem de posição no filme, direção do hemisfério, posicao na fonte, interrupção do raio



Amostragem de caminhos

Espaço de amostragem primário

- ▶ Caminho construído a partir de geração de número randômicos: $u = f(\xi)$
 - ▶ Amostragem de posição no filme, direção do hemisfério, posicao na fonte, interrupção do raio
- ▶ Amostragem primária de um caminho
 - ▶ $\mathbf{u} = [u_1, u_2, u_3, \dots] \in \mathcal{U} = [0, 1]^d$ (hipercubo)
 - ▶ $\mathbf{z} = S(\mathbf{u})$



Amostragem de caminhos

Espaço de amostragem primário

- ▶ Caminho construído a partir de geração de número randômicos: $u = f(\xi)$
 - ▶ Amostragem de posição no filme, direção do hemisfério, posicao na fonte, interrupção do raio
- ▶ Amostragem primária de um caminho
 - ▶ $\mathbf{u} = [u_1, u_2, u_3, \dots] \in \mathcal{U} = [0, 1]^d$ (hipercubo)
 - ▶ $\mathbf{z} = S(\mathbf{u})$

Reescrevendo a integral em relação ao espaço primário

$$L_j = \int_{\mathcal{U}} f(S(\mathbf{u})) \left| \frac{dS(\mathbf{u})}{d\mathbf{u}} \right| d\mathbf{u}$$

- ▶ Avaliando o determinante da inversa do mapeamento

$$\left| \frac{dS(\mathbf{u})}{d\mathbf{u}} \right| = \frac{1}{p_S(\mathbf{u})}, \text{ onde } p_S(\mathbf{u}) \text{ é probabilidade do caminho expresso em } \mathcal{U}$$



Transporte de luz por Metropolis

Amostragem do caminho

- ▶ Amostra inicial $\mathbf{z}_0$
- ▶ Mutação $T(\mathbf{z}_i \rightarrow \mathbf{z}_t)$
- ▶ Probabilidade de aceitação $a(\mathbf{z}_i \rightarrow \mathbf{z}_t)$



Transporte de luz por Metropolis

Amostragem do caminho

- ▶ Amostra inicial $\mathbf{z}_0$
- ▶ Mutação $T(\mathbf{z}_i \rightarrow \mathbf{z}_t)$
- ▶ Probabilidade de aceitação $a(\mathbf{z}_i \rightarrow \mathbf{z}_t)$

Pseudo código

for $i = 1$ **to** M **do**

Based on $\mathbf{z}_i$, sample a tentative point $\mathbf{z}_t$ using $T(\mathbf{z}_i \rightarrow \mathbf{z}_t)$

$$a(\mathbf{z}_i \rightarrow \mathbf{z}_t) = \frac{I(\mathbf{z}_t) \cdot T(\mathbf{z}_t \rightarrow \mathbf{z}_i)}{I(\mathbf{z}_i) \cdot T(\mathbf{z}_i \rightarrow \mathbf{z}_t)}$$

// accept with probability $a(\mathbf{z}_i \rightarrow \mathbf{z}_t)$

Generate random number r in $[0, 1]$.

if $r < a(\mathbf{z}_i \rightarrow \mathbf{z}_t)$ **then** $\mathbf{z}_{i+1} = \mathbf{z}_t$

else $\mathbf{z}_{i+1} = \mathbf{z}_i$

endfor



Transporte de luz por Metropolis

Ajustes para traçado de caminhos

- ▶ Gera várias sementes $\mathbf{z}$ e estima $b = \int I(\mathbf{z})d\mathbf{z}$
- ▶ Escolhe $\mathbf{z}_0$ entre as sementes de forma proporcional a $I(\mathbf{z})$
- ▶ Usa amostras futuras não aceitas com peso proporcional à taxa de aceitação



Transporte de luz por Metropolis

Ajustes para traçado de caminhos

- ▶ Gera várias sementes $\mathbf{z}$ e estima $b = \int I(\mathbf{z})d\mathbf{z}$
- ▶ Escolhe $\mathbf{z}_0$ entre as sementes de forma proporcional a $I(\mathbf{z})$
- ▶ Usa amostras futuras não aceitas com peso proporcional à taxa de aceitação

Lembrando:

- ▶ Contribuição em um pixel j

$$L_j = \int_{\mathcal{P}} f(\mathbf{z})d\mathbf{z} \approx \frac{1}{M} \sum_{i=1}^M \frac{f(\mathbf{z}_i)}{p(\mathbf{z}_i)}$$

- ▶ Normalização

$$p(\mathbf{z}) = \frac{I(\mathbf{z})}{b} \text{ com } b = \int_{\mathcal{P}} I(\mathbf{z})d\mathbf{z}$$

- ▶ Contribuição de um caminho

$$L_{\mathbf{z}_i} = \frac{b}{M} \frac{f(\mathbf{z}_i)}{I(\mathbf{z}_i)}$$



Transporte de luz por Metropolis

Pseudo código do processo de Markov

for $i = 1$ **to** M **do**

Based on $\mathbf{z}_i$, sample a tentative point $\mathbf{z}_t$ using $T(\mathbf{z}_i \rightarrow \mathbf{z}_t)$

$$a(\mathbf{z}_i \rightarrow \mathbf{z}_t) = \min \left\{ \frac{I(\mathbf{z}_t) \cdot T(\mathbf{z}_t \rightarrow \mathbf{z}_i)}{I(\mathbf{z}_i) \cdot T(\mathbf{z}_i \rightarrow \mathbf{z}_t)}, 1 \right\}$$

Select pixel j to which $\mathbf{z}_i$ contributes

$$\Phi_j += \frac{b}{M} \cdot \frac{F(\mathbf{z}_i)}{I(\mathbf{z}_i)} \cdot (1 - a(\mathbf{z}_i \rightarrow \mathbf{z}_t))$$

Select pixel k to which $\mathbf{z}_t$ contributes

$$\Phi_k += \frac{b}{M} \cdot \frac{F(\mathbf{z}_t)}{I(\mathbf{z}_t)} \cdot a(\mathbf{z}_i \rightarrow \mathbf{z}_t)$$

// accept with probability $a(\mathbf{z}_i \rightarrow \mathbf{z}_t)$

Generate random number r in $[0, 1]$.

if $r < a(\mathbf{z}_i \rightarrow \mathbf{z}_t)$ **then** $\mathbf{z}_{i+1} = \mathbf{z}_t$

else $\mathbf{z}_{i+1} = \mathbf{z}_i$


endfor



Mutação de caminhos

Caminhos parametrizados por $\mathbf{u} \in \mathcal{U}$

► Exemplo: $\mathbf{u} = [u_1, u_2, u_3, u_4, u_5, u_6, u_7, u_8]$



- u_1, u_2 : escolha da direção do raio no filme (ou pixel)
- u_3, u_4, u_5 : roleta russa e amostra de direção
- u_6 : roleta russa (que no caso falhou)
- u_7, u_8 : amostra de posição na fonte de luz



Combinação de caminhos

Suponha duas estratégias para mutação de caminhos

- ▶ Mutação pequena: perturbação local
 - ▶ Considere M_1 amostras com probabilidade de cada caminho $p_1(\mathbf{u}) = I(\mathbf{u})/b$
 - ▶ Probabilidade proporcional à contribuição do caminho
- ▶ Mutação grande: caminho totalmente novo
 - ▶ Considere M_2 amostras com probabilidade de cada caminho $p_2(\mathbf{u}) = 1$
 - ▶ Probabilidade de seleção uniforme de pontos em $[0, 1)$
- ▶ Probabilidade de escolher uma mutação grande é p_{large}
 - ▶ Temos: $M_2 = p_{large}M$, onde $M = M_1 + M_2$



Combinação de caminhos

Suponha duas estratégias para mutação de caminhos

- ▶ Mutação pequena: perturbação local
 - ▶ Considere M_1 amostras com probabilidade de cada caminho $p_1(\mathbf{u}) = I(\mathbf{u})/b$
 - ▶ Probabilidade proporcional à contribuição do caminho
- ▶ Mutação grande: caminho totalmente novo
 - ▶ Considere M_2 amostras com probabilidade de cada caminho $p_2(\mathbf{u}) = 1$
 - ▶ Probabilidade de seleção uniforme de pontos em $[0, 1)$
- ▶ Probabilidade de escolher uma mutação grande é p_{large}
 - ▶ Temos: $M_2 = p_{large}M$, onde $M = M_1 + M_2$
- ▶ Usando MIS, temos o peso

$$w(\mathbf{u}) = \frac{1}{M_1 p_1(\mathbf{u}) + M_2 p_2(\mathbf{u})}$$



Combinação de caminhos

Considerando a estratégia de combinar contribuição com base na aceitação a

- ▶ Contribuição de um caminho antigo

$$(1 - a)w(\mathbf{u})f(\mathbf{u}) = \frac{(1 - a)f(\mathbf{u})}{(I(\mathbf{u})/b + p_{large})M}$$

- ▶ Mutações pequena são apenas amostras de Metropolis

$$a w(\mathbf{u})f(\mathbf{u}) = \frac{a f(\mathbf{u})}{(I(\mathbf{u})/b + p_{large})M}$$

- ▶ Mutações grandes são amostras de Metropolis e não correlata ao mesmo tempo

$$a w(\mathbf{u})f(\mathbf{u}) + w(\mathbf{u})f(\mathbf{u}) = \frac{(a + 1)f(\mathbf{u})}{(I(\mathbf{u})/b + p_{large})M}$$



Geração de caminhos

Amostras de Metropolis

- ▶ Note que caminhos podem ser encurtados e aumentados (Roleta Russa)
 - ▶ Quando encurtado e depois aumentado, amostras u_i anteriores reaproveitadas
 - ▶ Evitar misturar u_i relacionados a caminhos de câmera e fonte quando bidirecional



Geração de caminhos

Amostras de Metropolis

- Note que caminhos podem ser encurtados e aumentados (Roleta Russa)
 - Quando encurtado e depois aumentado, amostras u_i anteriores reaproveitadas
 - Evitar misturar u_i relacionados a caminhos de câmera e fonte quando bidirecional




Figura extraída de Kelemen et al., 2002

Geração de caminhos

Mutações

- ▶ Se $\xi_1 < p_{large}$, gera novo caminho do início
- ▶ Se não, performa mutação local

i = escolha aleatória de qual índice da amostragem primária

$\delta = s_2 e^{-\log \frac{s_2}{s_1} \xi_2}$, com $\delta \in [s_1, s_2]$

if $\xi_3 < 0.5$ **then**

$$u_i = u_i + \delta$$

else


$$u_i = u_i - \delta$$

- ▶ Com, por exemplo $s_1 = 1/1024$ e $s_2 = 1/64$




Resultados

Regular path tracing



Bidirectional tracing



Multiplexed Metropolis

